

depth 0

RTX 40-series	564	3.8k	194	714	1.3k		572	65	158	129
RTX 5070	716	3.8k	252	620	1.2k		521	65	147	113
RTX 5080	716	5.4k	259	896	1.9k	242	663	72	178	140
RX 7900 XT	7.1k	3.3k	2.2k	836	1.2k		633	34	437	411
Arc B580	1.9k	1.7k	926	486	686		410	51	258	239
Iris Xe (iGPU)	196	292	68		98				32	
M-series (Safari)	1.1k				152					
M2	1.1k	521	255	64	149		73	35	55	36
M3 (16 GB)	1.7k	772	399	121	246	169	170	48	79	58
M4 (32 GB)	3.6k	2.0k	981		612				211	
iPhone 15	316	71	47							
iPhone 17 Pro Max	414	108	77			23				
Adreno 7xx	89	86	31							
Snapdragon X Elite	223	140	47	29	39	25	26	14	10	11
Galaxy S24	159	137	69	29	60	29	30			
PowerVR D-series		34	13				7			

depth 2048

RTX 40-series	266	3.5k	42	241	1.1k		185	37	32	25
RTX 5070	296	3.1k	42	272	909	41	176	38	29	22
RTX 5080	313	4.9k	46	330	1.5k	46	174	39	28	24
RX 7900 XT	6.2k	3.3k	2.1k	819	1.2k	881	624	16	434	409
Arc B580	750	1.6k	470	455	513	353	335	42	192	163
Iris Xe (iGPU)	114	255	17	56	76	14			12	3
M-series (Safari)	721				133					
M2	509	438	144	65	108	93	72	23	40	28
M3 (16 GB)	728	657	212	154	180	138	124	30	43	43
M4 (32 GB)	1.7k	1.7k	521		480				169	
iPhone 15	161	62	37							
iPhone 17 Pro Max	246	94	59			23				
Adreno 7xx	68	86	12							
Snapdragon X Elite	108	140	14	25	40	11	21	9	7	6
Galaxy S24	99	109	83	36	67	41	29			
PowerVR D-series	68	31					7			

gemma3 (0.25 GB) lfm (0.23 GB) qwen3 (0.40 GB) granite (0.90 GB) llama (0.81 GB) bonsai* (0.25 GB) qwen3.5 (1.28 GB) gemma4 (3.11 GB) smollm (1.92 GB) ministral (2.15 GB)

Prefill tokens / second (log scale)

1k

100

10