

depth 0

RTX 40-series	3.8k		564	194	714	572	158	129	65	1.3k
RTX 5070	3.8k	174	716	252	620	521	147	113	65	1.2k
RTX 5080	5.4k	242	716	259	896	663	178	140	72	1.9k
RX 7900 XT	3.3k	881	7.1k	2.2k	836	633	437	411	34	1.2k
Arc B580	1.7k	674	1.9k	926	486	410	258	239	51	686
Iris Xe (iGPU)	292	30	196	68	72		32	18		98
M-series (Safari)	118		1.1k	77						152
M2	521	132	1.1k	255	64	73	55	36	35	149
M3 (16 GB)	1.1k	245	1.4k	387	210	230	105	87	59	311
M4 (32 GB)	1.9k	534	3.6k	973	396	417	211	193	73	609
iPhone 15	71		316	47						
iPhone 17 Pro Max	108	23	414	77						
Adreno 7xx	86		89	31						
Snapdragon X Elite	140	25	223	47	29	26	10	11	14	39
Galaxy S24	137	29	159	69	29	30				60
Mali (Valhall)	46			18						
PowerVR D-series	34		72	13		7				

depth 2048

RTX 40-series	3.5k		266	42	241	185	32	25	37	1.1k
RTX 5070	3.1k	40	296	42	272	176	29	22	38	909
RTX 5080	4.9k	46	313	46	330	174	28	24	39	1.5k
RX 7900 XT	3.3k	862	6.2k	2.1k	819	624	434	409	16	1.2k
Arc B580	1.6k	348	750	470	455	335	192	163	42	513
Iris Xe (iGPU)	255	14	114	17	56		12	3		76
M-series (Safari)	73		721	44						133
M2	438	94	509	144	65	72	40	28	23	108
M3 (16 GB)	759	114	448	138	187	178	61	47	33	187
M4 (32 GB)	1.7k	358	1.7k	520	374	385	168	145	45	474
iPhone 15	62		161	37						
iPhone 17 Pro Max	94	23	246	59						
Adreno 7xx	86		68	12						
Snapdragon X Elite	140	11	108	14	25	21	7	6	9	40
Galaxy S24	109	41	99	83	36	29				67
Mali (Valhall)										
PowerVR D-series	31		68	10		7				

Prefill tokens / second (log scale)

1k

100

10